Compressão de Textos

🎓 **Aluno**: Lucas de Araújo
Matrícula: 18.2.4049
Professor Doutor: Guilherme Tavares de Assis

Introdução
- Aspectos Relevantes
- Razão de Compressão

Métodos de Codificação
- Algoritmo de Huffman
  - Compressão de Huffman Usando Palavras
  - Árvore de Codificação
- Algoritmo de Moffat e Katajainen
  - Fases do Algoritmo

Códigos Canônicos
- Codificação e Decodificação
- Compressão
- Descompressão

Introdução

O problema de compressão de texto consiste, de forma resumida, na representação de textos originais provindo de documentos em um menor espaço na memória. Sua ideia primária é caracterizada pela substituição dos símbolos dos textos por outros símbolos, porém estes, ocupando um número menor de *bits* ou *bytes*.

O ganho obtido está no fato do texto comprimido ocupar menos espaço de armazenamento, levando menos tempo para ser pesquisado, lido do disco ou transmitido por um canal de comunicação

Porém, o preço pago por isto será o custo computacional maior para realizar o processo de codificação e decodificação do texto

Aspectos Relevantes

Além da economia de espaço, podemos citar alguns outros aspectos relevantes:

- **Velocidade de Compressão e Descompressão**: Em muitas situações, a velocidade de descompressão é mais importante que a de compressão
    - Exemplo: Banco de dados Textuais
- **Possibilidade de realizar casamento de cadeias diretamente no texto comprimido**: A busca sequencial da cadeia comprimida pode ser bem mais eficiente do que descomprimir o texto a ser pesquisado
- **Acesso direto a qualquer parte do texto comprimido, possibilitando o início da descompressão a partir da parte acessada**: Um sistema de recuperação de informações para grandes coleções de documentos que estejam comprimidos necessita acesso direto a qualquer ponto do texto comprimido

Razão de Compressão

Razão de compressão corresponde à porcentagem (métrica) que o arquivo comprimido representa em relação ao tamanho do arquivo não comprimido. É utilizada geralmente para medir o ganho em espaço obtido por um método de compressão e para comparação de algoritmos

- Exemplo: Se o arquivo não comprimido possui $100\ \text{bytes}$ e o arquivo comprimido possui $30\ \text{bytes}$, a razão é de 30%

$$\frac{30}{100} * 100 = 30\%$$

✔️ Quanto menor o método de compressão, mais eficiente o algoritmo será

Métodos de Codificação

Algoritmo de Huffman

Proposto em 1952, um método de codificação bem conhecido e utilizado nos dias atuais é o de Huffman.

- Um código único, de tamanho variável, é atribuído a cada símbolo diferente do texto.
- Códigos mais curtos são atribuídos a símbolos com frequências altas.
- As implementações tradicionais do método de Huffman consideram caracteres como símbolos.

Para atender as necessidades dos sistemas de RI (Recuperação de Informação), deve-se considerar palavras como símbolos a serem codificados:

- Métodos de Huffman baseados em caracteres e em palavras comprimem o texto para cerca de 60% e 25% respectivamente

Compressão de Huffman Usando Palavras

Esta técnica de compressão corresponde a técnica mais eficaz para compressão de textos em linguagem natural. Um texto em linguagem natural é constituído de palavras e de separadores (caracteres que aparecem entre palavras,como espaço, vírgula, ponto, etc).

Ela consiste nos seguintes passos:

- Inicialmente, considera-se cada palavra diferente do texto como um símbolo, contado suas frequências e gerando um código de Huffman para as mesmas
  - A tabela de símbolos do codificador é exatamente o vocabulário do texto, o que permite uma integração natural entre o método de compressão e o arquivo invertido (Sistemas de RI)
- A seguir, o texto é comprimido, substituindo cada palavra pelo seu código correspondente
- A compressão será realizada em duas passadas sobre o texto:
  1. Obtenção da frequência de cada palavra diferente
  2. Realização da compressão

Uma forma eficiente de se lidar com as palavras e separadores é representar o espaço simples de forma implícita no texto comprimido.

- Se uma palavra é seguida de um espaço, somente a palavra será codificada. Caso contrário, a palavra e o separador são codificados de maneira separada
- No momento da decodificação, supõe-se que um espaço simples segue cada palavra, a não ser que o próximo símbolo corresponda a um separador

Árvore de Codificação

O algoritmo de Huffman constrói uma árvore de codificação, partindo-se de baixo para cima através dos seguintes passos:

- Inicialmente, há um conjunto de n folhas representando as palavras do vocabulário e suas respectivas frequências.
- A cada interação, as duas árvores com as menores frequências são combinadas em uma única árvore e a soma de suas frequências é associada ao nó raiz da árvore gerada.
- Ao final de $(n-1)$ iterações, obtém-se a árvore de codificação, na qual o código associado a uma palavra é representado pela sequência dos rótulos das arestas da raiz à folha que a representa

- Árvore de codificação para o texto:
  "para cada rosa rosa, uma rosa é uma rosa"

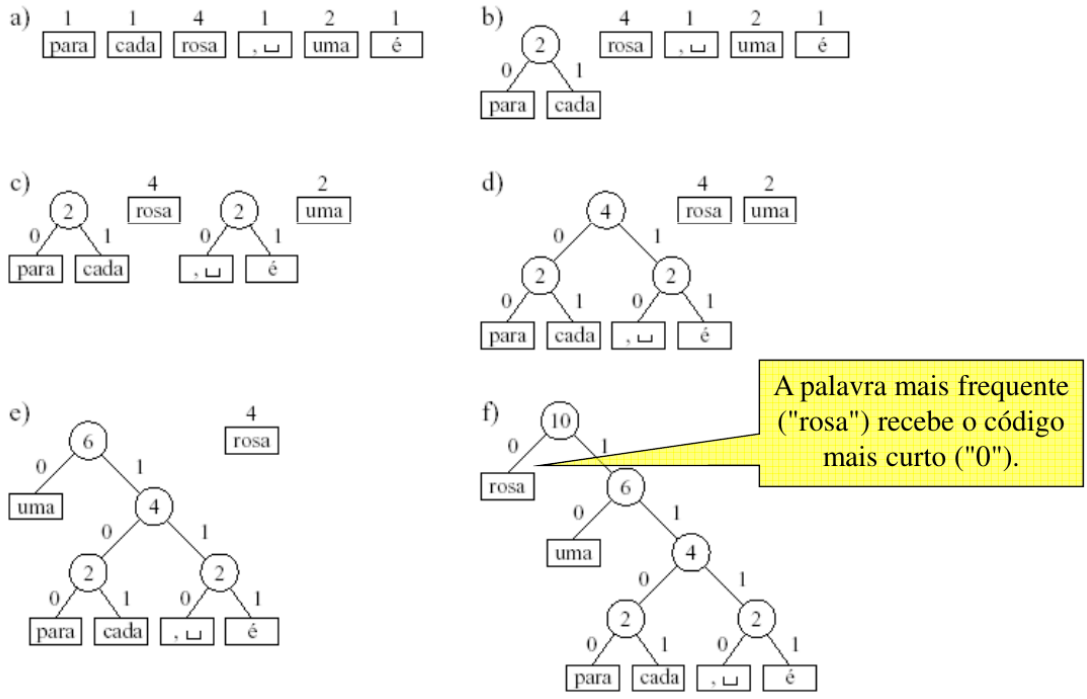

Exemplo retirado dos slides

O método de Huffman produz a árvore de codificação que acaba por minimizar o comprimento do arquivo comprimido. Existem várias árvores que produzem a mesma compressão

- Trocar o filho da à esquerda de um nó por um filho à direita leva a uma árvore de codificação alternativa com a mesma razão de compressão
- A escolha preferencial é a árvore canônica (árvore desbalanceada, onde um lado sempre será maior que o outro em termos de altura)
    - Uma árvore de Huffman é canônica quando a altura da subárvore à direita de qualquer nó nunca é menor que a altura da subárvore à esquerda

A representação do código por meio de uma árvore canônica de codificação facilita a visualização e sugere métodos triviais de codificação e decodificação

- **Codificação**: A árvore é percorrida emitindo bits ao longo de suas arestas.
- **Decodificação**: Os bits de entrada são usados para selecionar as arestas

> ❕ Essa abordagem é ineficiente tanto em termos de espaço quanto em termos de tempo.

> ✔️ Através do uso de estruturas como Árvore B, Árvore TRIE, podemos aumentar a eficiência do algoritmo pois aceleramos o processo de pesquisa.

Algoritmo de Moffat e Katajainen

Criado em 1995, o algoritmo de Moffat e Katajainen baseado na codificação canônica apresenta comportamento linear em tempo e espaço.

O algoritmo calcula os comprimentos dos códigos em lugar dos códigos propriamente ditos, com isto, a compressão atingida é a mesma, independente dos códigos utilizados. Após o cálculo dos comprimentos, há uma forma elegante e eficiente para codificação e a decodificação

A entrada do algoritmo é um vetor A contendo as frequências das palavras em ordem decrescente

- Para o texto $\text{"para cada rosa rosa, uma rosa é uma rosa"}$ o vetor A é:

4	2	1	1	1	1

- Durante a execução, são usados vetores logicamente distintos, porém, que coexistem no mesmo vetor A

Fases do Algoritmo

O algoritmo é dividido em **três** fases distintas:

📌 1) Combinação dos nós

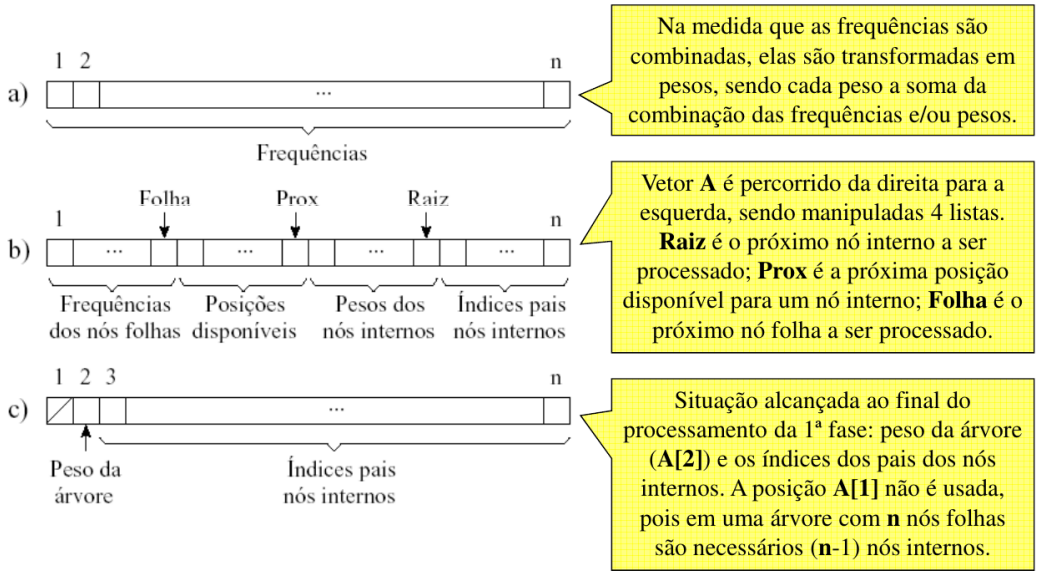

```
PrimeiraFase (A, n)
{ Raiz = n; Folha = n;
  for (Prox = n; n >= 2; Prox--)
  { /* Procura Posicao */
    if ((nao existe Folha) || ((Raiz > Prox) && (A[Raiz] <= A[Folha])))
    { A[Prox] = A[Raiz];  A[Raiz] = Prox;  Raiz = Raiz - 1; /* No interno */ }
    else { A[Prox] = A[Folha];  Folha = Folha - 1; /* No folha */ }
    /* Atualiza Frequencias */
    if ((nao existe Folha) || ((Raiz > Prox) && (A[Raiz] <= A[Folha])))
    { /* No interno */
      A[Prox] = A[Prox] + A[Raiz]; A[Raiz] = Prox; Raiz = Raiz - 1;
    }
    else { A[Prox] = A[Prox] + A[Folha]; Folha = Folha - 1; /* No folha */ }
  }
}
```

- Exemplo da primeira fase do algoritmo.

	1	2	3	4	5	6	Prox	Raiz	Folha
a)	4	2	1	1	1	1	6	6	6
b)	4	2	1	1	1	1	6	6	5
c)	4	2	1	1	1	2	5	6	4
d)	4	2	1	1	1	2	5	6	3
e)	4	2	1	1	2	2	4	6	2
f)	4	2	1	2	2	4	4	5	2
g)	4	2	1	4	4	4	3	4	2
h)	4	2	2	4	4	4	3	4	1
i)	4	2	6	3	4	4	2	3	1
j)	4	4	6	3	4	4	2	3	0
k)	/	10	2	3	4	4	1	2	0

2) Profundidades dos Nós Internos

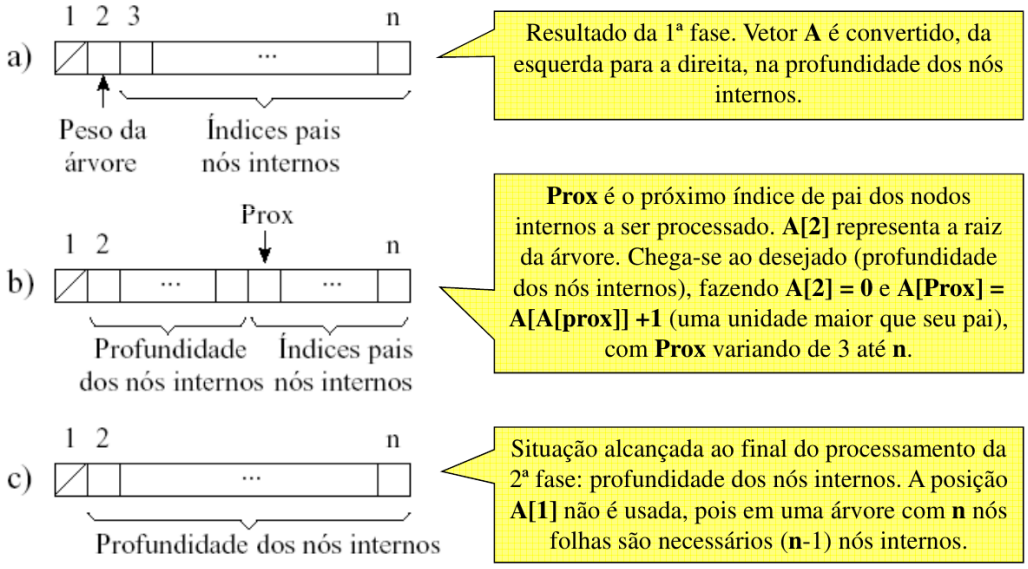


```
SegundaFase (A, n)
{ A[2] = 0;
  for (Prox = 3; Prox <= n; Prox++) A[Prox] = A[A[Prox]] + 1;
}
```

- Resultado da segunda fase:

	0	1	2	3	3

3) Profundidade dos Nós Folhas

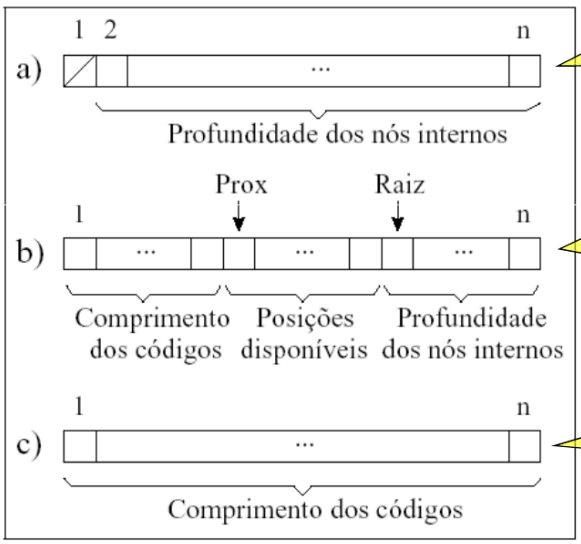

Resultado da 2ª fase. A partir daí, são calculadas as profundidades dos nós folhas, os quais representam os comprimentos dos códigos.

Vetor **A** é percorrido da esquerda para a direita, sendo manipuladas 3 listas. **Raiz** é o próximo nó interno a ser processado; **Prox** é a posição na qual o próximo comprimento de código deve ser armazenado.

Situação alcançada ao final do processamento da 3ª fase: profundidade dos nós folhas (comprimento dos códigos).

Disp armazena quantos nós estão disponíveis no nível **h** da árvore.
u indica quantos nós do nível **h** são internos.

```
TerceiraFase (A, n)
{ Disp = 1; u = 0; h = 0; Raiz = 2; Prox = 1;
  while (Disp > 0)
  { while (Raiz <= n && A[Raiz] == h) { u = u + 1; Raiz = Raiz + 1; }
    while (Disp > u) { A[Prox] = h; Prox = Prox + 1; Disp = Disp – 1; }
    Disp = 2 * u; h = h + 1; u = 0;
  }
}
```

- Resultado da terceira fase:

1	2	4	4	4	4

Programa completo para calcular o comprimento dos códigos a partir de um vetor de frequências:

```
CalculaCompCodigo (A, n)
{ A = PrimeiraFase (A, n);
  A = SegundaFase (A, n);
  A = TerceiraFase (A, n);
}
```

Códigos Canônicos

O código canônico possui as seguintes propriedades:

- Comprimento dos códigos seguem o algoritmo de Huffman
- Códigos de mesmo comprimento são inteiros consecutivos

A partir dos comprimentos obtidos pelo algoritmo apresentado, o cálculo dos códigos se torna simples:

- Primeiro código é composto apenas por zeros
- Os demais códigos, adiciona-se 1 ao código anterior e faz-se um deslocamento à esquerda para obter-se o comprimento adequado quando necessário

i	Símbolo	Código Canônico
1	rosa	0
2	uma	10
3	para	1100
4	cada	1101
5	,␣	1110
6	é	1111

Codificação e Decodificação

Os algoritmos são baseados no fato de que códigos de mesmo comprimento, são inteiros consecutivos.

c	Base[c]	Offset[c]
1	0	1
2	2	2
3	6	2
4	12	3

Os algoritmos usam dois vetores com $MaxCompCod$ (comprimento do maior código) elementos:

- $Base$: Indica que para um dado comprimento c, o valor inteiro do 1° código com tal comprimento

$$\text{Base}[c] = \begin{cases} 0 & \text{se } c = 1, \\ 2 \times (\text{Base}[c-1] + w_{c-1}) & \text{caso contrário,} \end{cases}$$

Nº de códigos com comprimento (**c-1**).

- $Offset$: Indica que para um dado comprimento c, o índice do vocabulário da 1° palavra de tal comprimento

```
Codifica (Base, Offset, i, MaxCompCod)
{ c = 1;
  while ( i >= Offset[c + 1] ) && (c + 1 <= MaxCompCod )
    c = c + 1;
  Codigo = i – Offset[c] + Base[c];
}
```

Parâmetros: vetores **Base** e **Offset**, índice **i** do símbolo a ser codificado e o comprimento **MaxCompCod** dos vetores.

Cálculo do comprimento **c** de código a ser utilizado.

O código corresponde à soma da ordem do código para o comprimento **c** (**i – Offset[c]**) com o valor inteiro do 1º código de comprimento **c** (**Base[c]**).

- Para $i = 4(\text{"cada"})$, calcula-se que seu código possui o comprimento 4 e verifica-se que é o 2° código de tal comprimento. Assim, seu código é dado por:
  - $13(4 - Offset[4] + Base[4]) : 1101$

Parâmetros: vetores **Base** e **Offset**, o arquivo comprimido e o comprimento **MaxCompCod** dos vetores.

```
Decodifica (Base, Offset, ArqComprimido, MaxCompCod)
{ c = 1;
  Codigo = LeBit (ArqComprimido);
  while ((( Codigo << 1 ) >= Base[c + 1]) && ( c + 1 <= MaxCompCod ))
    { Codigo = (Codigo << 1) || LeBit (ArqComprimido);
      c = c + 1;
    }
  i = Codigo – Base[c] + Offset[c];
}
```

Identifica o código a partir de uma posição do arquivo comprimido.

O arquivo de entrada é lido *bit*-a-*bit*, adicionando-se os *bits* lidos ao código e comparando-o com o vetor **Base**.

Decodificação da Sequência de Bits: 1101

c	LeBit	Codigo	Codigo $<< 1$	Base$[c+1]$
1	1	1	-	-
2	1	10 **or** 1 = 11	10	10
3	0	110 **or** 0 = 110	110	110
4	1	1100 **or** 1 = 1101	1100	1100

- A 1ª linha da tabela é o estado inicial do *while*, quando já foi lido o primeiro *bit* da sequência, atribuído à *Codigo*.
- As linha seguintes representam a situação do anel *while* após cada respectiva iteração.
  - Na linha dois, o segundo *bit* foi lido (*bit* 1) e *Codigo* recebe o código anterior deslocado à esquerda de um *bit* seguido da operação *or* com o bit lido.
- De posse do código, *Base* e *Offset* são usados para identificar o índice i da palavra no vocabulário:

$$i = Codigo - Base[c] + Offset[c]$$

Compressão

O processo de compressão é realizado em 3 etapas:

- Na primeira etapa, o arquivo texto é percorrido e o vocabulário é gerado juntamente com a frequência de cada palavra.
    - Uma tabela hash tratada com tratamento de colisão é utilizada para que as operações de inserção e pesquisa no vetor de vocabulário sejam realizadas em $O(1)$

```
Compressao (ArqTexto, ArqComprimido)
{ /* Primeira etapa */
  while (!feof (ArqTexto))
    { Palavra = ExtraiProximaPalavra (ArqTexto);
      Pos = Pesquisa (Palavra, Vocabulario);
      if Pos é uma posicao valida
      Vocabulario[Pos].Freq = Vocabulario[Pos].Freq + 1
      else Insere (Palavra, Vocabulario);
    }
```

- Na segunda etapa, temos:
    - O vetor Vocabulário é ordenado pelas frequências de suas palavras
    - Calcula-se o comprimento dos códigos (Algoritmo de Moffat e Katajainen)
    - Os vetores $Base, Offset$ e $Vocabulário$ são construídos e gravados no ínicio do arquivo comprimido
    - A tabela hash é reconstruída a partir da leitura do vocabulário no disco, como preparação para a terceira etapa

```
/* Segunda etapa */
Vocabulario = OrdenaPorFrequencia (Vocabulario);
Vocabulario = CalculaCompCodigo (Vocabulario, n);
ConstroiVetores (Base, Offset, ArqComprimido);
Grava (Vocabulario, ArqComprimido);
LeVocabulario (Vocabulario, ArqComprimido);
```

- Por fim, na terceira etapa, temos:

- O arquivo texto é novamente percorrido
- As palavras são extraidas e codificadas
- Os códigos correspondentes são gravados no arquivo comprimido

```
  /* Terceira etapa */
  PosicionaPrimeiraPosicao (ArqTexto);
  while (!feof(ArqTexto))
    { Palavra = ExtraiProximaPalavra (ArqTexto);
      Pos = Pesquisa (Palavra, Vocabulario);
      Codigo = Codifica (Base, Offset,
                         Vocabulario[Pos].Ordem, MaxCompCod);
      Escreve (ArqComprimido, Codigo);
    }
}
```

Descompressão

O processo de descompressão é mais simples do que o de compressão e consiste no seguinte:

- É feita a leitura dos vetores $Base$,$Offset$ e $Vocabulario$ gravados no ínicio do arquivo comprimido
- É feita a leitura dos códigos do arquivo comprimido, descodificando-os e gravando as palavras correspondentes no arquivo texto

```
Descompressao (ArqTexto, ArqComprimido)
{ LerVetores (Base, Offset, ArqComprimido);
  LeVocabulario (Vocabulario, ArqComprimido);
  while (!feof(ArqComprimido))
    { i = Decodifica (Base, Offset, ArqComprimido, MaxCompCod);
      Grava (Vocabulario[i], ArqTexto);
    }
}
```